

Receita Cinematográfica: Uma Abordagem com Modelos Generalizados Aditivos

Guilherme Duarte Alves Basso- RA: 240805
Rafaela da Silva Barril - RA: 204368
Vitor Ribas Perrone - RA: 245040

1 Introdução

A indústria cinematográfica movimenta bilhões de dólares anualmente e representa um dos principais segmentos da economia do entretenimento. Entretanto, o sucesso comercial de um filme é influenciado por uma combinação complexa de fatores relacionados às características da produção, às estratégias de lançamento e à recepção do público. Nesse contexto, compreender quais atributos estão associados ao desempenho financeiro de uma obra constitui uma questão de grande interesse tanto para estúdios e distribuidoras quanto para investidores e pesquisadores.

Diversas características podem influenciar a receita de um filme, como o orçamento destinado à produção, a duração, o gênero, a companhia produtora, o idioma original, o período de lançamento e a avaliação média atribuída pelo público. Embora parte desses efeitos possa ser aproximadamente linear, é plausível que algumas relações apresentem comportamentos mais complexos. Por exemplo, aumentos no orçamento podem produzir retornos crescentes apenas até determinado ponto, enquanto a duração do filme pode apresentar um intervalo considerado mais favorável ao desempenho de bilheteria. Dessa forma, impor relações estritamente lineares pode resultar em modelos pouco flexíveis e incapazes de representar adequadamente a dinâmica dos dados.

Nesse cenário, os Modelos Generalizados Aditivos (GAM) constituem uma alternativa natural aos Modelos Lineares Generalizados, pois permitem modelar efeitos não lineares das covariáveis contínuas por meio de funções suaves, preservando simultaneamente a interpretabilidade do modelo e a inclusão de efeitos paramétricos para variáveis categóricas. Essa flexibilidade possibilita representar relações complexas entre as covariáveis e a variável resposta sem a necessidade de especificar previamente uma forma funcional para cada efeito.

2 Objetivo

O objetivo deste trabalho é modelar a receita de filmes a partir de características relacionadas à produção e ao lançamento das obras, identificando os fatores associados ao desempenho comercial e avaliando a natureza de seus efeitos sobre a arrecadação. Para isso, utiliza-se um Modelo Aditivo Generalizado (GAM), permitindo que as covariáveis contínuas sejam representadas por funções suaves sempre que houver evidências de relações não lineares, enquanto as variáveis categóricas são incorporadas de forma paramétrica.

Além do ajuste do modelo, busca-se avaliar a significância estatística dos efeitos lineares e não lineares das covariáveis, interpretar os impactos das características dos filmes sobre a receita esperada e verificar a adequação do modelo por meio de técnicas de diagnóstico baseadas em resíduos quantílicos simulados.

3 Metodologia

3.1 Modelo Generalizado Aditivo (GAM)

Seja uma amostra aleatória $Y_1, \dots, Y_n$, em que $\mu_i = \mathbb{E}(Y_i)$ representa a média da variável resposta associada à i -ésima observação. Considere $x_{i1}, x_{i2}, \dots, x_{ik}$ como covariáveis contínuas cujos efeitos sobre a resposta são potencialmente não lineares, e Z_i como a linha da matriz de planejamento correspondente às covariáveis discretas e às covariáveis contínuas com efeito linear. Nessas condições, o modelo adotado é definido pela seguinte estrutura:

$$g(\mu_i) = \sum_{l=1}^k f_l(x_{il}) + Z_i\beta,$$

em que $g(\cdot)$ representa a função de ligação associada à distribuição da variável resposta, $f_l(\cdot)$ são funções suaves referentes a cada covariável contínua não linear e β representa o vetor de parâmetros associados às covariáveis categóricas e contínuas lineares.

3.2 Estimação dos Parâmetros

Para a estimação dos parâmetros, o método utilizado é Máxima Verossimilhança, isto é, assim como nos MLG tradicionais, o objetivo é resolver:

$$(\widehat{\beta}, \widehat{f}_1, \dots, \widehat{f}_k) = \arg \max_{\beta, f_1, \dots, f_k} \ell(\beta, f_1, \dots, f_k)$$

Entretanto, assim como nos MLG, não existe solução exata para o problema, sendo necessário utilizar um método iterativo, no caso, o algoritmo de backshifting, que consiste em atualizar de forma intercalada os componentes paramétricos (β) e os componentes funcionais ($f_1, \dots, f_k$).

O primeiro passo consiste em inicializar todos os parâmetros como 0, ou seja, $\beta^{(0)} = \mathbf{0}$ e $f_1^{(0)}, \dots, f_k^{(0)} = 0$ em todo ponto do domínio. A partir disso, ocorrem etapas iterativas até o algoritmo convergir. O critério de convergência é a Deviance deixar de diminuir entre as iterações. Isto é, um certo $\epsilon > 0$ é fixado e o algoritmo para quando, para uma certa iteração m ,

$$\frac{|Deviance^{(m)} - Deviance^{(m-1)}|}{Deviance^{(m-1)} + 0.1} < \epsilon$$

Dessa forma, uma determinada iteração m é dada pelos seguintes passos:

1. Atualização de Quantidades

Para $i = 1, \dots, n$:

$$\begin{aligned}\eta_i^{(m-1)} &= \sum_{l=1}^k f_l^{(m-1)}(x_{il}) + Z_i \boldsymbol{\beta}^{(m-1)} \\ \mu_i^{(m-1)} &= g^{-1}(\eta_i^{(m-1)}) \\ z_i^{(m-1)} &= \eta_i^{(m-1)} + (y_i - \mu_i^{(m-1)}) \left(\frac{d\mu_i}{d\eta_i}(\eta_i^{(m-1)}) \right) \\ w_i^{(m-1)} &= \left(\frac{d\mu_i}{d\eta_i}(\eta_i^{(m-1)}) \right)^2 \frac{1}{V(\mu_i^{(m-1)})}\end{aligned}$$

Dessa forma,

$$W^{(m-1)} = \text{diag}(w_1^{(m-1)}, \dots, w_n^{(m-1)})$$

2. Atualização de Coeficientes Paramétricos

$$\begin{aligned}R_{P_i}^{(m)} &= z_i^{(m-1)} - \sum_{l=1}^k f_l^{(m-1)}(x_{il}) \\ \boldsymbol{\beta}^{(m)} &= (X^T W^{(m-1)} X)^{-1} X^T W^{(m-1)} \mathbf{R}_P^{(m)}\end{aligned}$$

3. Atualização de Componentes Funcionais

Para $j = 1, \dots, k$:

$$\begin{aligned}R_{j_i}^{(m)} &= z_i^{(m-1)} - X_i \boldsymbol{\beta}^{(m)} - \sum_{l=1}^{j-1} f_l^{(m)}(x_{il}) - \sum_{l=j+1}^k f_l^{(m-1)}(x_{il}) \\ f_j^{(m)} &= \arg \min_{f_j} \sum_{i=1}^n (R_{j_i}^{(m)} - f_j(x_{ij}))^2 + \lambda_j \int_{\mathbb{R}} (f_j''(x))^2 dx, \text{ sob a restrição } \sum_{i=1}^n f_j(x_{ij}) = 0 \text{ e penalização } \lambda_j.\end{aligned}$$

Essa otimização é realizada utilizando bases splines, isto é, podemos escrever

$$f_j^{(m)} = B_j^{(m)} \boldsymbol{\theta}_j^{(m)},$$

em que $B_j^{(m)}$ é a matriz das funções de base splines e $\boldsymbol{\theta}_j^{(m)}$ é o vetor de coeficientes associado a essas funções de base. Dessa forma, a estimação da função suave $f_j(\cdot)$ reduz-se à estimação dos coeficientes de $\boldsymbol{\theta}_j^{(m)}$, sujeita à penalização que controla a suavidade da curva.

A partir disso,

$$\hat{\boldsymbol{\theta}}_j^{(m)} = (B_j^{(m)T} W^{(m-1)} B_j^{(m)} + \lambda_j \boldsymbol{\Omega}_j)^{-1} B_j^{(m)T} W^{(m-1)} \mathbf{R}_j^{(m)}, \text{ tal que } \boldsymbol{\Omega}_j \text{ é a matriz de penalização.}$$

Com isso,

$$f_j^{(m)} = B_j^{(m)} \boldsymbol{\theta}_j^{(m)} = B_j^{(m)} (B_j^{(m)T} W^{(m-1)} B_j^{(m)} + \lambda_j \boldsymbol{\Omega}_j)^{-1} B_j^{(m)T} W^{(m-1)} \mathbf{R}_j^{(m)} = S_j^{(m)} \mathbf{R}_j^{(m)}$$

3.3 Inferência dos Parâmetros

3.3.1 Coeficientes Paramétricos

Os testes de hipótese para os efeitos dos componentes paramétricos consistem em testar as seguintes hipóteses:

$$H_0 : \beta_j = 0$$

$$H_1 : \beta_j \neq 0$$

A mesma aproximação assintótica que é utilizada nos GLM pode ser aplicada em GAM, isto é, a distribuição assintótica é dada por:

$$\hat{\boldsymbol{\beta}} \xrightarrow[n \rightarrow \infty]{d} N(\boldsymbol{\beta}, (X^T W X)^{-1} \hat{\phi})$$

Dessa forma, os testes de hipótese para os componentes paramétricos podem ser realizados da mesma forma em que são realizados nos GLM.

3.3.2 Coeficientes Funcionais

Para os componentes funcionais, existem dois testes de interesse, avaliar se o preditor apresenta significância e avaliar se o componente é linear, ou seja, se não é necessário utilizar um componente funcional para tal. Para isso, é possível expressar as funções referentes aos componentes funcionais separando a parte linear da não linear, isto é:

$$f_j(x) = a_j x + g_j(x)$$

A partir disso, é possível realizar cada um dos testes de interesse. Para o teste referente a verificar se o componente é linear, as hipóteses de interesse são dadas por:

$$\begin{aligned} H_0 : g_j(x) &= 0 \\ H_1 : g_j(x) &\neq 0 \end{aligned}$$

A estatística de teste é:

$$T_j = \frac{1}{\hat{\phi}} \sum_{i=1}^n \left[w_i \left(g_j(x_{ij}) - \hat{g}_j(x_{ij}) \right)^2 + 2 w_i g_j(x_{ij}) r_i \right],$$

em que $\hat{g}_j(x_{ij})$ é a projeção de $g_j(x_{ij})$ sobre o espaço paramétrico, r_i é o resíduo do modelo completo e $\hat{\phi} = \frac{\sum_{i=1}^n w_i r_i^2}{n - q}$ é o estimador da dispersão residual, para distribuições que possuem parâmetro de dispersão, em que q é a soma dos graus de liberdade referentes a cada um dos parâmetros do modelo, sendo o número de graus de liberdade de um componente funcional dado por $\text{tr}(\mathbf{S}_j)$. Sob H_0 , para distribuições que possuem parâmetro de dispersão:

$$F_j = \frac{T_j}{\nu_j} \xrightarrow[n \rightarrow \infty]{d} F(\nu_j, n - q),$$

em que $\nu_j = \text{tr}(\mathbf{S}_j) - 1$ são os graus de liberdade não-lineares do componente j . Para distribuições sem parâmetro de dispersão:

$$T_j \xrightarrow[n \rightarrow \infty]{d} \chi^2(\nu_j).$$

Já o segundo teste, referente a verificar se o parâmetro é significativo, pode ser expresso considerando apenas o componente linear, uma vez que o primeiro teste estuda a significância da parte não linear. Dessa forma, as hipóteses são dadas por:

$$\begin{aligned} H_0 : a_j &= 0 \\ H_1 : a_j &\neq 0 \end{aligned}$$

Para realizar este teste, sejam $\mathbf{r}_j^*$ os resíduos parciais de x_j após ajustar todos os demais termos paramétricos e $\mathbf{W} = \text{diag}(w_1, \dots, w_n)$. A soma de quadrados atribuída ao componente linear $a_j x_j$ é:

$$SQ_j = \frac{(\mathbf{x}_j^T \mathbf{W} \mathbf{r}_j^*)^2}{\mathbf{x}_j^T \mathbf{W} \mathbf{x}_j}.$$

Com isso, a estatística do teste para distribuições que possuem parâmetro de dispersão é:

$$F_j = \frac{SQ_j / 1}{\hat{\phi}},$$

em que $p = k + \text{posto}(Z)$. Sob, H_0 ,

$$F_j \xrightarrow[n \rightarrow \infty]{d} F(1, n - p).$$

Já para as distribuições que não possuem parâmetro de dispersão,

$$SQ_j \xrightarrow[n \rightarrow \infty]{d} \chi^2(1).$$

3.3.3 Resíduos Quantílicos por DHARMA

O resíduo quantílico usual é dado por

$$q_i = F(y_i; \hat{\theta}),$$

na sua forma em que não se utiliza a acumulada inversa da Normal. Contudo, para distribuições discretas ou para modelos em que a variabilidade é difícil de especificar, esse resíduo não é exatamente Uniforme(0,1), mesmo quando o modelo está correto.

O pacote DHARMA, por sua vez, utiliza uma abordagem simulacional que produz resíduos uniformes independentemente da distribuição original. Em vez de computar diretamente a função de distribuição acumulada, o método constrói uma versão empírica da distribuição condicionada ao modelo. O procedimento consiste em:

1. Simular d conjuntos de dados a partir do modelo ajustado, mantendo a matriz de planejamento observada (ou seja, simulando $Y^{(1)}, \dots, Y^{(d)}$ como se o modelo fosse verdadeiro);
2. Para cada observação i , obter a distribuição empírica formada pelos valores simulados $Y_i^{(1)}, \dots, Y_i^{(d)}$;
3. Gerar uma amostra auxiliar $U_i \sim \text{Uniforme}(0, 1)$;
4. Calcular o resíduo quantílico uniforme: $u_i = \frac{\#\{Y_i^{(k)} < y_i\}}{d} + U_i \frac{\#\{Y_i^{(k)} = y_i\}}{d}$.

Dessa forma, o DHARMA produz uma versão simulada dos resíduos. Em distribuições contínuas, praticamente não há empates, de modo que o segundo termo desaparece. Já em distribuições discretas, esse termo aleatoriza corretamente a massa de probabilidade acumulada em cada ponto. Com isso, caso o modelo apresente bom ajuste, é esperado que a distribuição dos resíduos seja Uniforme(0,1).

4 Aplicação em Dados Reais

4.1 Descrição do Banco de Dados

Para a aplicação prática do modelo, utilizou-se um conjunto de dados composto por informações de aproximadamente 10.000 filmes extraídas da plataforma *The Movie Database* (TMDB). Antes do ajuste dos modelos, o conjunto de dados passou por etapas de limpeza, filtragem e reagrupamento de categorias, visando reduzir a alta dimensionalidade de algumas variáveis e garantir maior estabilidade e interpretabilidade das estimativas.

O banco de dados possui as seguintes variáveis:

- **Variável Resposta:**

- Receita (revenue): Faturamento global bruto arrecadado pelo filme (em dólares).

- **Covariáveis Numéricas (Componentes Funcionais):**

- Orçamento (budget): Custo total de produção da obra cinematográfica;
- Duração (runtime): Tempo de duração total do filme mensurado em minutos;
- Nota Média (vote_average): Pontuação média de avaliação atribuída pelos usuários na base do TMDB, variando em uma escala de 0 a 10;
- Ano (year): Ano do lançamento do filme nos cinemas.

- **Covariáveis Categóricas (Componentes Paramétricos):**

- Mês (month): Mês de lançamento do filme, tratado como um fator composto por 12 níveis (variando de month01 a month12).
- Idioma Original (original_language): Idioma nativo da produção. Foram mantidos apenas os idiomas de maior dominância, o inglês (en) e o francês (fr) enquanto os demais foram agrupados em “Outros”.
- Gênero Adaptado (genres_adap): Gênero cinematográfico principal atribuído à obra. Para viabilizar o ajuste, foram mantidas as classes com representatividade expressiva (Action, Adventure, Animation, Comedy, Crime, Drama, Family, Fantasy, Horror, Romance, Science Fiction e Thriller) e as de menor volume foram unificadas em “Outros”.
- Produtora Principal (prod_comp): Estúdio ou companhia de produção responsável pelo desenvolvimento do filme. O fator preserva individualmente os grandes estúdios consolidados de Hollywood (Columbia Pictures, New Line Cinema, Paramount Pictures, Universal Pictures, Walt Disney Pictures e Warner Bros. Pictures), enquanto companhias independentes ou de menor porte foram categorizadas como “Outros”.

4.2 Análise exploratória

Para a variável resposta, a Figura 1 mostra que a distribuição da receita (revenue) é fortemente assimétrica positiva. A grande maioria das produções cinematográficas concentra-se em faixas de faturamento mais modestas, enquanto uma pequena parcela atinge valores extremos na casa dos bilhões de dólares.




Figura 1: Distribuição da variável resposta Receita (em milhões de dólares).

Com o objetivo de compreender a variabilidade da receita (revenue), a Figura 2 apresenta o comportamento da receita em relação às variáveis contínuas. Sendo assim, no que se refere ao orçamento (budget), observa-se pela Figura 2(a) uma associação positiva clara entre as variáveis, acompanhada de forte heterocedasticidade: orçamentos elevados aumentam o potencial de faturamento, mas também ampliam a dispersão dos resultados, gerando tanto sucessos bilionários quanto grandes fracassos comerciais. Para a variável tempo de filme, a Figura 2(b) exibe um comportamento não monotônico para a variável runtime, com os picos de faturamento concentrados entre 100 e 130 minutos; extremos de duração raramente faturam alto, o que justifica o uso do componente flexível do modelo GAM. Em relação à nota média (vote_average), pela Figura 2(c), observa-se que produções mal avaliadas enfrentam um teto rígido de faturamento modesto, enquanto os fenômenos comerciais exigem aceitação crítica superior. Por fim, para o ano (year), observa-se pela Figura 2(d) uma tendência de crescimento exponencial nos tetos de arrecadação nas últimas décadas.




Figura 2: Distribuição da receita em relação ao budget, runtime, vote_average e year.

A Tabela 1 apresenta as medidas resumo para todas as variáveis contínuas. Sendo assim, uma observação muito importante é o fato da variância da variável resposta (revenue) ser consideravelmente maior do que a média, o que sugere que seja utilizada a distribuição Binomial Negativa ao invés da Poisson na modelagem.

Tabela 1: Medidas de resumo para as variáveis contínuas

Variável	Média	Mediana	Desvio Padrão	Mínimo	Máximo
revenue	133.200.00	58.460.000	216.326.800	1	2.924.000.000
budget	41.736.092	25.000.000	49.817.660	5	460.000.000
runtime	112	108	21,89	0	254
vote_average	6,7	6,71	0,77	1	8,71

Em sequência, a Figura 3 detalha o comportamento da receita para as variáveis qualitativas. Pela Figura 3(a) referente ao gênero de filme nota-se que Animação, Aventura e Família lideram o retorno financeiro central. Já pela Figura 3(b), evidenciam-se o amplo domínio dos grandes estúdios tradicionais de Hollywood (como Warner Bros., Universal, Paramount e Disney), que concentram as maiores medianas de receita, mas com forte presença de outliers para filmes com estúdios caracterizados em “Outros”. Adicionalmente, a Figura 3(c) evidencia um claro padrão sazonal no mercado cinematográfico, com as maiores medianas de receita e maior incidência de outliers bilionários concentrados nos meses de maio, junho, julho e dezembro. Por último, a Figura 3(d), referente ao idioma original, mostra que os filmes produzidos em inglês (en) apresentam receitas medianas significativamente superiores às observadas para os demais idiomas.




Figura 3: Distribuição da receita em relação ao gênero, produtora principal, mês e idioma.

4.3 Modelo Completo

Concluída a Análise Exploratória, avançou-se para a etapa de Modelagem Estatística. Nesse processo, ajustou-se um modelo completo, utilizando a distribuição Binomial Negativa devido à superdispersão na variável resposta, contemplando todas as variáveis e usando a parametrização casela de referência para as categóricas, em que o grupo de referência é dado por mês 1 (month1), língua inglesa (original_languageen), gênero de ação (genres_adapAction) e produtora Columbia Pictures (prod_compColumbia Pictures). As tabelas com os resultados referentes ao modelo completo estão presentes no Anexo 7, de modo que a Tabela 5 apresenta os p-valores dos testes referentes à parte não linear para os componentes funcionais. Em sequência, a Tabela 6 apresenta os p-valores dos testes referentes à parte linear para os componentes funcionais, enquanto a Tabela 7 apresenta os resultados obtidos pelo teste de Wald para as variáveis categóricas, bem como as estimativas dos parâmetros.

Observa-se que, para os parâmetros funcionais, apenas $s(\text{vote_average})$ não rejeitou a hipótese de que a parte não linear é igual a zero. No que tange os efeitos da parte linear, todos parâmetros funcionais foram significativos. Ou seja, vote_average apresenta significância apenas em sua parte linear. Já para os coeficientes categóricos, 17 parâmetros não rejeitaram a hipótese nula, sendo 8 deles referente aos meses (mês 2, mês 4, mês 5, mês 6, mês 7, mês 8, mês 11 e mês 12), 4 referentes ao gênero do

filme (Aventura, Fantasia, Romance e Ficção Científica) e 5 referentes a companhia de produção (New Lime Cinema, Paramount Pictures, Universal Pictures, Disney Pictures, e Warner Bros. Pictures).

Em relação à interpretação dos parâmetros, os coeficientes funcionais apresentam interpretações distintas dos coeficientes paramétricos. Em detalhes, algumas das interpretações possíveis a partir do modelo são apresentadas na Subseção 4.3.1 e 4.3.2.

4.3.1 Variáveis categóricas

Para a variável `genres_adapAnimation` tem-se como interpretação que filmes classificados na categoria Animation apresentam um aumento de 0.2804 unidades no logaritmo da receita média em relação à categoria de referência da variável `genres_adap`, mantendo as demais variáveis fixas.

Para as demais variáveis tem-se uma interpretação análoga de acordo com suas estimativas e respectivos grupos de referência.

4.3.2 Variáveis contínuas funcionais

A Figura 4(a) apresenta os valores estimados para a variável $f(\text{budget})$, em que é possível avaliar o efeito do `budget` ao longo dos possíveis valores. Com isso, mantendo as demais variáveis fixas, observa-se que aumentos no orçamento estão associados a aumentos no logaritmo da receita média. Contudo, esse efeito não é constante, uma vez que para filmes de baixo orçamento, pequenos aumentos no orçamento estão associados a grandes aumentos na receita esperada, enquanto para filmes de orçamento elevado o ganho adicional tende a ser menor.

Para as variáveis $f(\text{runtime})$, $f(\text{vote_average})$ e $f(\text{year})$ tem-se interpretações semelhantes de acordo com suas curvas ilustradas respectivamente por Figura 4(b), Figura 4(c) e Figura 4(d). É interessante ressaltar que $f(\text{vote_average})$ apresenta um comportamento aproximadamente linear, conforme evidenciado nos testes de hipótese.




Figura 4: Funções de suavização estimadas para as variáveis `budget`, `runtime`, `vote_average` e `year`.

4.3.3 Análise de Resíduos

Em acréscimo, é imprescindível verificar a qualidade de ajuste a fim de garantir a confiabilidades dos testes de hipótese realizados. Nesse sentido, utilizou-se o resíduo quantílico DHARMA, em que a distribuição esperada é dada por uma $\text{Uniforme}(0,1)$. Sendo assim, pela Figura 5(a) observa-se que os resíduos seguem aproximadamente uma distribuição uniforme e pela Figura 5(b) se comportam razoavelmente bem em torno da reta, evidenciando, portanto, um bom ajuste, mas com leves ressalvas.




Figura 5: Gráfico de resíduos DHARMA para o modelo completo.

4.4 Modelo Reduzido

Em sequência, optou-se por ajustar um modelo reduzido, considerando a variável `vote_average` sem ser um componente funcional, uma vez que para esta variável apenas a parte linear apresentou significância. A distribuição Binomial Negativa foi mantida, e nenhuma variável categórica foi removida e nem agrupada, dado que apesar de algumas categorias não serem significativas, existe a significância global. Além disso, o grupo de referência foi mantido.

Nota-se, então, que, pela Tabela 2, todos os parâmetros funcionais permanentes no modelo rejeitaram a hipótese referente à parte não linear, além de que, pela Tabela 3, todos obtiveram efeito significativo no teste referente à parte linear. Por sua vez, a Tabela 4 mostra que 14 parâmetros categóricos não rejeitaram a hipótese nula, sendo 6 deles referente aos meses (mês 2, mês 5, mês 6, mês 7, mês 8, mês 11 e mês 12), 4 referentes ao gênero do filme (Aventura, Fantasia, Romance e Ficção Científica) e 5 referentes a companhia de produção (New Lime Cinema, Paramount Pictures, Universal Pictures, Disney Pictures, e Warner Bros. Pictures).

Tabela 2: Testes de hipótese para a parte não linear dos componentes funcionais do modelo reduzido

Parâmetro	g.l.	Valor F	P-valor
f(budget)	3	134.6026	$< 2.2 \times 10^{-16}$
f(runtime)	3	4.0266	0.0072
f(year)	3	62.3779	$< 2.2 \times 10^{-16}$

Tabela 3: Testes de hipótese para a parte linear dos componentes funcionais do modelo reduzido

Parâmetro	g.l.	SQ	SQM	Valor F	P-valor
f(budget)	1	3064.2999	3064.2999	2508.5772	$< 2.2 \times 10^{-16}$
f(runtime)	1	37.1794	37.1794	30.4368	3.64×10^{-8}
f(year)	1	20.7662	20.7662	17.0002	3.8×10^{-5}

Em acréscimo, as interpretações dos parâmetros apresentados nas Tabelas 3 e 4 podem ser realizadas de forma análoga ao modelo completo. As interpretações se encontram na Subseção 4.4.1, Subseção 4.4.2 e Subseção 4.4.3.

4.4.1 Variáveis contínuas funcionais

A Figura 6(a) apresenta os valores estimados para a variável `f(runtime)`, em que é possível avaliar o efeito do `runtime` ao longo dos possíveis valores. Com isso, mantendo as demais variáveis fixas, observa-se uma relação positiva e não linear entre a duração do filme e o logaritmo da receita média. Nos menores tempos de duração, o efeito cresce de forma relativamente acentuada. Em seguida, há uma região em que a curva apresenta inclinação reduzida, indicando que o impacto financeiro de aumentos adicionais na duração é mais moderado. Por fim, para filmes com duração mais elevada, a inclinação da curva volta a aumentar, evidenciando que longas durações estão associadas a um crescimento mais intenso no logaritmo da receita média. Assim, os resultados sugerem que o efeito da duração não pode ser adequadamente descrito por uma relação linear, justificando a utilização de uma função de suavização no modelo.

Para as variáveis `f(budget)` e `f(year)` tem-se interpretações semelhantes de acordo com suas curvas ilustradas, respectivamente, por Figura 6(b), Figura 6(c).




Figura 6: Funções de suavização estimadas para as variáveis budget, runtime e year no modelo ajustado.

4.4.2 Variáveis contínuas lineares

Pela Tabela 4, para a variável `vote_average` tem-se que para cada aumento de uma unidade, sem variação nos demais parâmetros, obtém-se um aumento de 4.5765 unidades no log médio da receita.

4.4.3 Variáveis categóricas

Pela Tabela 4, para a variável `month2` tem-se como interpretação que filmes lançados em fevereiro apresentam uma redução de 0.0554 unidades no logaritmo da receita média em relação à categoria de referência `month1`, mantendo as demais variáveis fixas. Para as demais variáveis, a interpretação é análoga de acordo com suas estimativas e respectivos grupos de referência.

Tabela 4: Valores estimados e testes Wald para coeficientes categóricos e contínuos lineares do modelo reduzido

Parâmetro	Estimativa	Erro Padrão	Valor Z	P-valor
Intercepto	19.0817	2.2481	8.4881	$< 2.2 \times 10^{-16}$
<code>vote_average</code>	4.5765	2.4435	18.7289	$< 2.2 \times 10^{-16}$
<code>month02</code>	-0.0554	0.0938	-0.5910	0.5545
<code>month03</code>	-0.1936	0.0914	-2.1171	0.0343
<code>month04</code>	-0.1870	0.0952	-1.9654	0.0494
<code>month05</code>	-0.0630	0.0931	-0.6769	0.4985
<code>month06</code>	0.0374	0.0901	0.4154	0.6779
<code>month07</code>	0.0670	0.0894	0.7490	0.4538
<code>month08</code>	-0.1715	0.0893	-1.9207	0.0548
<code>month09</code>	-0.2313	0.0889	-2.6015	0.0093
<code>month10</code>	-0.2046	0.0882	-2.3182	0.0204
<code>month11</code>	-0.1100	0.0907	-1.2126	0.2253
<code>month12</code>	-0.0673	0.0866	-0.7770	0.4372
<code>original_languagefr</code>	-0.4103	0.1124	-3.6519	0.0003
<code>original_languageOutros</code>	-0.2619	0.0634	-4.1286	3.65×10^{-5}
<code>genres_adapAdventure</code>	0.0637	0.0718	0.8866	0.3753
<code>genres_adapAnimation</code>	0.2834	0.0881	3.2179	0.0013
<code>genres_adapComedy</code>	0.2148	0.0585	3.6736	0.0002
<code>genres_adapCrime</code>	-0.4169	0.0867	-4.8106	1.5×10^{-6}
<code>genres_adapDrama</code>	-0.2481	0.0578	-4.2946	1.75×10^{-5}
<code>genres_adapFamily</code>	0.2861	0.1079	2.6512	0.0080
<code>genres_adapFantasy</code>	0.1227	0.1035	1.1860	0.2356
<code>genres_adapHorror</code>	0.4266	0.0691	6.1778	6.5×10^{-10}
<code>genres_adapOutros</code>	-0.1922	0.0883	-2.1778	0.0294
<code>genres_adapRomance</code>	0.0252	0.1097	0.2296	0.8184
<code>genres_adapScience Fiction</code>	-0.1469	0.0922	-1.5925	0.1113
<code>genres_adapThriller</code>	-0.1998	0.0887	-2.2528	0.0243
<code>prod_compNew Line Cinema</code>	0.0366	0.1401	0.2615	0.7937
<code>prod_compOutros</code>	-0.2042	0.0908	-2.2473	0.0246
<code>prod_compParamount Pictures</code>	0.0430	0.1194	0.3603	0.7187
<code>prod_compUniversal Pictures</code>	0.0345	0.1196	0.2885	0.7730
<code>prod_compWalt Disney Pictures</code>	-0.1168	0.1418	-0.8235	0.4102
<code>prod_compWarner Bros. Pictures</code>	-0.2460	0.1311	-1.8766	0.0606

4.4.4 Análise de Resíduos

Por fim, tal como foi feito para o modelo completo, foram utilizados os resíduos quantílicos DHARMA para a análise residual do modelo. Observa-se que os resíduos do modelo ajustado ilustrados na Figura 7 foram muito semelhantes aos resíduos do modelo completo ilustrados na Figura 5. Assim, tal como observado para o modelo completo, os resíduos do modelo reduzido, pela Figura 7(a), seguem aproximadamente uma distribuição uniforme e, pela Figura 7(b) se comportam razoavelmente bem em torno da reta, evidenciando, então, um ajuste bom, mas com leves ressalvas.




Figura 7: Gráfico de resíduos DHARMA para o modelo ajustado.

5 Conclusão

Neste trabalho, utilizou-se um Modelo Aditivo Generalizado (GAM) com distribuição Binomial Negativa para modelar a receita de filmes em função de características relacionadas ao orçamento, duração, avaliação, ano de lançamento e variáveis categóricas referentes ao mês de lançamento, idioma original, gênero e companhia produtora. A escolha da distribuição Binomial Negativa mostrou-se adequada por acomodar a superdispersão presente na variável resposta, enquanto a estrutura aditiva do GAM possibilitou representar adequadamente relações não lineares entre a receita e algumas variáveis explicativas.

Os resultados evidenciaram que o orçamento, o tempo de duração e o ano de lançamento apresentam efeitos não lineares significativos sobre o logaritmo da receita média, justificando a utilização de funções de suavização para essas variáveis. Em particular, observou-se que o orçamento exerce impacto direto sobre a receita, apresentando um crescimento mais acentuado para filmes de menor orçamento, assim, à medida que o orçamento aumenta, o logaritmo da receita média continua crescendo, porém em um ritmo menos intenso. O tempo de duração também apresentou um comportamento não linear, indicando que o efeito de aumentos na duração varia ao longo de sua faixa de valores. Em contrapartida, a variável `vote_average` não apresentou evidências de não linearidade, sendo, portanto, adequadamente representada por um efeito linear no modelo ajustado.

Além dos efeitos contínuos, verificou-se que algumas categorias de mês de lançamento, idioma original, gênero e companhia produtora influenciam significativamente a receita esperada dos filmes, evidenciando que características qualitativas também desempenham papel importante na explicação da variável resposta.

De maneira geral, os resultados obtidos demonstram que o uso de Modelos Aditivos Generalizados foi apropriado para este problema, uma vez que permitiu identificar e representar relações complexas que dificilmente seriam capturadas por um modelo linear tradicional. A flexibilidade proporcionada pelas funções de suavização possibilitou modelar efeitos distintos ao longo da faixa de valores das variáveis contínuas, produzindo interpretações mais realistas e um ajuste estatístico consistente. Assim, conclui-se que o modelo ajustado é capaz de compreender os fatores associados à receita de filmes, conciliando flexibilidade, interpretabilidade e boa qualidade de ajuste.

6 Bibliografia

- ASHEN PABASARA. TMDb Box Office Dataset for Prediction. Disponível em: <<https://www.kaggle.com/datasets/ashenp/tmdb-box-office-dataset-for-prediction>>. Acesso em: 30 maio. 2026.
- Buja, A., Hastie, T. and Tibshirani, R. (1989). Linear Smoothers and Additive Models. *The Annals of Statistics*, 17(2), pp.453–510. doi:<https://doi.org/10.1214/aos/1176347115>.
- Eilers, P.H.C. and Marx, B.D. (1996). Flexible smoothing with B-splines and penalties. *Statistical Science*, 11(2), pp.89–121. doi:<https://doi.org/10.1214/ss/1038425655>.
- Hastie, T. and Tibshirani, R. (1986). Generalized Additive Models. *Statistical Science*, 1(3), pp.297–310. doi:<https://doi.org/10.1214/ss/1177013604>.
- The Movie Database. Disponível em: <<https://www.themoviedb.org/?lang>>. Acesso em: 30 maio. 2026.
- Wood, SN 2025, 'Generalized Additive Models', *Annual Review of Statistics and its Application*, vol. 12, no. 1, pp. 497-526. <https://doi.org/10.1146/annurev-statistics-112723-034249>

Tabela 5: Testes de hipótese para a parte não linear dos componentes funcionais do modelo completo

Parâmetro	g.l.	Valor F	P-valor
f(budget)	3	134.8666	$< 2.2 \times 10^{-16}$
f(runtime)	3	3.924	0.0083
f(vote_average)	3	0.8688	0.4565
f(year)	3	61.9239	$< 2.2 \times 10^{-16}$

Tabela 6: Testes de hipótese para a parte linear dos componentes funcionais do modelo completo

Parâmetro	g.l.	SQ	SQM	Valor F	P-valor
f(budget)	1	3065.4358	3065.4358	2514.9798	$< 2.2 \times 10^{-16}$
f(runtime)	1	35.8796	35.8796	29.4368	1×10^{-7}
f(vote_average)	1	425.6785	425.6786	349.2401	$< 2.2 \times 10^{-16}$
f(year)	1	21.0339	21.0339	17.2569	3.32×10^{-5}

Tabela 7: Valores estimados e testes Wald para coeficientes categóricos do modelo completo

Parâmetro	Estimativa	Erro Padrão	Valor Z	P-valor
Intercepto	19.1308	2.2456	8.5192	$< 2.2 \times 10^{-16}$
month02	-0.0545	0.0937	-0.5814	0.5610
month03	-0.1950	0.0913	-2.1348	0.0328
month04	-0.1860	0.0951	-1.9570	0.0503
month05	-0.0650	0.0930	-0.6987	0.4848
month06	0.0377	0.0900	0.4190	0.6752
month07	0.0672	0.0893	0.7529	0.4515
month08	-0.1721	0.0892	-1.9290	0.0537
month09	-0.2308	0.0888	-2.5997	0.0093
month10	-0.2058	0.0881	-2.3345	0.0196
month11	-0.1099	0.0906	-1.2134	0.2250
month12	-0.0660	0.0865	-0.7634	0.4452
original_languagefr	-0.4125	0.1122	-3.6758	0.0002
original_languageOutros	-0.2640	0.0634	-4.1651	3.11×10^{-5}
genres_adapAdventure	0.0614	0.0718	0.8555	0.3923
genres_adapAnimation	0.2804	0.0880	3.1870	0.0014
genres_adapComedy	0.2125	0.0584	3.6378	0.0003
genres_adapCrime	-0.4192	0.0866	-4.8425	1.28×10^{-6}
genres_adapDrama	-0.2490	0.0577	-4.3145	1.6×10^{-5}
genres_adapFamily	0.2862	0.1078	2.6551	0.0079
genres_adapFantasy	0.1222	0.1034	1.1821	0.2372
genres_adapHorror	0.4273	0.0690	6.1945	5.85×10^{-10}
genres_adapOutros	-0.1936	0.0882	-2.1956	0.0281
genres_adapRomance	0.0277	0.1096	0.2524	0.8008
genres_adapScience Fiction	-0.1455	0.0921	-1.5789	0.1144
genres_adapThriller	-0.2002	0.0886	-2.2604	0.0238
prod_compNew Line Cinema	0.0313	0.1400	0.2236	0.8231
prod_compOutros	-0.2061	0.0907	-2.2716	0.0231
prod_compParamount Pictures	0.0416	0.1193	0.3487	0.7273
prod_compUniversal Pictures	0.0316	0.1194	0.2650	0.7910
prod_compWalt Disney Pictures	-0.1163	0.1417	-0.8208	0.4118
prod_compWarner Bros. Pictures	-0.2478	0.1309	-1.8924	0.0584